

04_Operaciones_Sobre_Filtrado

November 28, 2023



0.1 Operaciones sobre subconjuntos

En esta sesión vamos a aprovechar lo aprendido sobre filtrado en la anterior para trabajar solo con parte del dataframe, de forma que podamos hacer cálculos más precisos, obtener respuestas más concretas y manipular datos de una manera selectiva.

Y para empezar, como en las últimas sesiones, recuperemos nuestra `DataFrame` de referencia:

```
[1]: import numpy as np
import pandas as pd

df_aviones = pd.read_csv("../data/dataset_inicial_aviones.csv", index_col = "Id_vuelo")
```

```
[27]: df_aviones
```

```
[27]:
```

	Aircompany	Origen	Destino	Distancia	\
Id_vuelo					
Air_PaGi_10737	Airnar	París	Ginebra	411	
Fly_BaRo_10737	FlyQ	Bali	Roma	12738	
Tab_GiLo_11380	TabarAir	Ginebra	San Francisco	9103	
Mol_PaCi_10737	MoldaviAir	París	Cincinnati	6370	
Tab_CiRo_10747	TabarAir	Cincinnati	Roma	7480	
...	
Tab_LoLo_11320	TabarAir	Los Angeles	Londres	8785	
Mol_CiLo_10737	MoldaviAir	Cincinnati	Londres	6284	
Fly_RoCi_11320	FlyQ	Roma	Cincinnati	7480	

Tab_RoLo_10747	TabarAir	Roma	Londres	1433
Air_PaLo_10737	Airnar	París	Los Angeles	9099

	avion	consumo_kg	duracion	supertrayectos
Id_vuelo				
Air_PaGi_10737	Boeing 737	1028.691900	51	False
Fly_BaRo_10737	Boeing 737	33479.132544	1167	True
Tab_GiLo_11380	Airbus A380	109439.907200	626	False
Mol_PaCi_10737	Boeing 737	17027.010000	503	False
Tab_CiRo_10747	Boeing 747	86115.744000	518	False
...
Tab_LoLo_11320	Airbus A320	24766.953120	756	False
Mol_CiLo_10737	Boeing 737	16491.729600	497	False
Fly_RoCi_11320	Airbus A320	19721.049920	662	False
Tab_RoLo_10747	Boeing 747	15734.053400	115	False
Air_PaLo_10737	Boeing 737	22331.675700	711	False

[1200 rows x 8 columns]

0.1.1 Operaciones y Consultas Selectivas

Para empezar vamos a realizar algunas operaciones de las que hicimos hace dos sesiones pero ahora ya podemos ser más selectivos

NOTA PERSONAL :El metodo **groupby** divide el DataFrame en grupos de filas y columnas y cada grupo contendrá filas con valores idénticos en las columnas de agrupación, obteniendo un objeto de grupo con referencias a cada uno de los grupos creados, Despues puedes hacer operaciones diversas en esos grupos como la media, la suma, el máximo, el mínimo o cualquier otra operación en función de tus necesidades.

```
[40]: #METODO FACIL PARA MAS ADEALNTE#
      """ mayor distancia por compañías
      Distancia_company = df_aviones.groupby("Aircompany")["Distancia"].max()#
      ↪agrupame en el dataframe las compañías con las mayores distancias recorridas
      ↪en sus viajes
      display(Distancia_company)"""
```

```
[40]: ' mayor distancia por compañías\nDistancia_company =
df_aviones.groupby("Aircompany")["Distancia"].max()# agrupame en el dataframe
las compañías con las mayores distancias recorridas en sus
viajes\ndisplay(Distancia_company) '
```

```
[2]: ### mayor distancia por compañías:

      """#creo un diccionario para guarda de la mayor distancia recorrida por compañía
      dict_mayor_dist_c = {}
```

```

# Obtener las compañías únicas
company_unicas = df_aviones['Aircompany'].unique()
#print(company_unicas) # lista de las 5 compañías

# Iterar a través de las compañías únicas, filtrando el DF por compañía
for company in company_unicas:
    listado_company = df_aviones[df_aviones['Aircompany'] == company]
    #print(listado_company) # extrayendo un listado de 231 elementos con
    ↪informacion del DF

    # calculo con un array la distancia máxima para cada compañía
    distancia_maxima = np.max(listado_company['Distancia'])
    #print(distancia_maxima)# 5 distancias maximas

    # Guardo la distancia máxima en el diccionario (diccionario - clave - valor)
    dict_mayor_dist_c [company] = distancia_maxima
    #print(company) # misma informacion que company_unicas pero al iterar esta
    ↪en una columna

# Imprimir la mayor distancia por compañía, iterando por el dict en clave y
    ↪valor
for company, distancia in dict_mayor_dist_c.items():
    print(f"La Compañía {company}, ha recorrido un total de {distancia}
    ↪kilometros, siendo su mayor distancia recorrida")"""

```

```

[2]: '#creo un diccionario para guarda de la mayor distancia recorrida por
compañía\ndict_mayor_dist_c = {}\n\n# Obtener las compañías
únicas\ncompany_unicas =
df_aviones[\'Aircompany\'].unique()\n#print(company_unicas) # lista de las 5
compañias\n\n# Iterar a través de las compañías únicas, filtrando el DF por
compañía\nfor company in company_unicas:\n    listado_company =
df_aviones[df_aviones[\'Aircompany\'] == company]\n    #print(listado_company) #
extrayendo un listado de 231 elementos con informacion del DF\n    \n    #
calculo con un array la distancia máxima para cada compañía \n
distancia_maxima = np.max(listado_company[\'Distancia\'])\n
#print(distancia_maxima)# 5 distancias maximas\n\n    # Guardo la distancia
máxima en el diccionario (diccionario - clave - valor)\n    dict_mayor_dist_c
[company] = distancia_maxima\n    #print(company) # misma informacion que
company_unicas pero al iterar esta en una columna\n\n# Imprimir la mayor
distancia por compañía, iterando por el dict en clave y valor\nfor company,
distancia in dict_mayor_dist_c.items():\n    print(f"La Compañía {company}, ha
recorrido un total de {distancia} kilometros, siendo su mayor distancia
recorrida")'

```

```

[3]: ### mayor distancia por compañías:## ESTA ES LA DEL PROFE

```

```

# itero sobre el las compañías del DF en valores unicos no todos los valores de
↳ las 1200 columnas
for company in df_aviones["Aircompany"].unique():
    distancia_max = df_aviones.loc[df_aviones["Aircompany"] == company,
↳ "Distancia"]# hago un filtrado con una serie panda con la mascara
↳ (DF[compañia ])de las compañías del DF como filtro == me quedo con las
↳ compañías y distancia
    # cumplen la condicion
    print(f"La mayor distancia cubierta por la compañía {company} es de
↳ {distancia_max} Km.")

```

La mayor distancia cubierta por la compañía Airnar es de Id_vuelo

Air_PaGi_10737	411
Air_GiCa_11380	1725
Air_GiLo_10747	9103
Air_BaGi_11380	12383
Air_BaCa_10737	12798

...

Air_PaCa_11320	1447
Air_GiCa_10737	1725
Air_GiCa_10747	1725
Air_GiCa_11320	1725
Air_PaLo_10737	9099

Name: Distancia, Length: 218, dtype: int64 Km.

La mayor distancia cubierta por la compañía FlyQ es de Id_vuelo

Fly_BaRo_10737	12738
Fly_RoNu_11320	6877
Fly_GiCi_10737	6969
Fly_GiRo_10737	698
Fly_BaGi_10737	12383

...

Fly_NuBa_11380	6170
Fly_NuRo_11320	6877
Fly_BaRo_10747	12738
Fly_GiBa_11380	12383
Fly_RoCi_11320	7480

Name: Distancia, Length: 216, dtype: int64 Km.

La mayor distancia cubierta por la compañía TabarAir es de Id_vuelo

Tab_GiLo_11380	9103
Tab_CiRo_10747	7480
Tab_LoCi_10737	3073
Tab_CiLo_10747	3073
Tab_GiLo_11380	739

...

Tab_NuGi_10747	6206
Tab_GiCi_11320	6969

```

Tab_GiLo_10737    9103
Tab_LoLo_11320    8785
Tab_RoLo_10747    1433
Name: Distancia, Length: 271, dtype: int64 Km.
La mayor distancia cubierta por la compañía MoldaviAir es de Id_vuelo
Mol_PaCi_10737    6370
Mol_CaMe_10737    20029
Mol_PaLo_11320    344
Mol_LoBa_11380    12553
Mol_MeCa_10737    20029
...
Mol_PaLo_11320    344
Mol_PaMe_11380    16925
Mol_LoCi_10737    6284
Mol_BaLo_10737    12553
Mol_CiLo_10737    6284
Name: Distancia, Length: 264, dtype: int64 Km.
La mayor distancia cubierta por la compañía PamPangea es de Id_vuelo
Pam_PaMe_11380    16925
Pam_NuBa_10737    16589
Pam_MePa_10737    16925
Pam_GiNu_11320    6206
Pam_MeBa_10737    2779
...
Pam_GiMe_10747    16674
Pam_BaMe_11320    2779
Pam_GiMe_10737    16674
Pam_BaNu_10747    16589
Pam_NuMe_11380    16082
Name: Distancia, Length: 231, dtype: int64 Km.

```

```

[17]: #METODO FACIL PARA MAS ADEALNTE#
      """viaje_menor = df_aviones.groupby("avion")["consumo_kg"].min()# agrupame en el dataframe las aviones con los menores consumo por viaje
      print(viaje_menor)"""

```

```

avion
Airbus A320    863.4400
Airbus A380    3976.6400
Boeing 737     835.9200
Boeing 747    3740.3808
Name: consumo_kg, dtype: float64

```

```

[3]: """#### Cual es el viaje con menor consumo por tipo de avion

# creo un diccionario para los viajes con menor consumo por tipo de avión
dict_menor_consumo_avion = {}

```

```

# Encuentra los tipos únicos de avión
tipos = df_aviones["avion"].unique()
#print(tipos)# una lista con 4 tipos de aviones

# Itera a través de los tipos de avión, filtrando el DF para cada tipo de avion
for tipo_avion in tipos:
    avionacos = df_aviones[df_aviones["avion"] == tipo_avion]
    #print(avionacos) #extrayendo un listado de 315 elementos con informaion de
    ↪todas las columnas de DF

    # claculo el índice de la fila donde se encuentre el valor minimo del viaje
    ↪con el menor consumo en ese tipo de avión
    indice_ecologista = avionacos["consumo_kg"].idxmin()
    #print(indice_ecologista) # informacion con id de 4 vuelos que seran los
    ↪de menor consumo

    # mediante una serie panda obtengo la fila correspondiente al viaje con el
    ↪menor consumo
    viaje_ecologista = avionacos.loc[indice_ecologista]

    # guardo el resultado en el diccionario (dict - clave - valor)
    dict_menor_consumo_avion[tipo_avion] = viaje_ecologista

# Imprimo los viajes con menor consumo por tipo de avión, iterando por el dict
    ↪en clave y calor
for tipo_avion, viaje in dict_menor_consumo_avion.items():
    print(f"El Tipo de Avión {tipo_avion} ha realizado los siguientes viajes
    ↪con menor consumo:\n {viaje}\n")"""

```

```

[3]: '#### Cual es el viaje con menor consumo por tipo de avion \n\n# creo un
diccionario para los viajes con menor consumo por tipo de
avión\ndict_menor_consumo_avion = {} \n\n# Encuentra los tipos únicos de
avión\ntipos = df_aviones["avion"].unique() \n#print(tipos)# una lista con 4
tipos de aviones\n\n# Itera a través de los tipos de avión, filtrando el DF para
cada tipo de avion\nfor tipo_avion in tipos:\n    avionacos =
df_aviones[df_aviones["avion"] == tipo_avion]\n    #print(avionacos) #extrayendo
un listado de 315 elementos con informaion de todas las columnas de DF\n
\n    # claculo el índice de la fila donde se encuentre el valor minimo del viaje
con el menor consumo en ese tipo de avión\n    indice_ecologista =
avionacos["consumo_kg"].idxmin()\n    #print(indice_ecologista) # informacion
con id de 4 vuelos que seran los de menor consumo\n    \n    # mediante una
serie panda obtengo la fila correspondiente al viaje con el menor consumo\n
viaje_ecologista = avionacos.loc[indice_ecologista]\n    \n    # guardo el
resultado en el diccionario (dict - clave - valor)\n
dict_menor_consumo_avion[tipo_avion] = viaje_ecologista\n\n# Imprimo los viajes
con menor consumo por tipo de avión, iterando por el dict en clave y calor\nfor

```

```
tipo_avion, viaje in dict_menor_consumo_avion.items():\n    print(f"El Tipo de Avión {tipo_avion} ha realizado los siguientes viajes con menor consumo:\n {viaje}\n")'
```

```
[30]: #METODO FACIL PARA MAS ADEALNTE#
      """aviones_company = df_aviones.groupby("avion")["Aircompany"].unique()#
      ↳agrupame el el DF los tipos de avion que esa las compañías en una lista de
      ↳valores unicos
      print("Las compañías que usan cada tipo de avion son\n",aviones_company)
      print("\n")
      numero_aviones_company = df_aviones.groupby("avion")["Aircompany"].nunique()#
      ↳agrupa el numero de compañías que usas los diferentes tipos de aviones a
      ↳partir de valores unicos en la columna "avion" de cada compañía
      display("El numero de compañías que usan los distintos tipos de aviones
      ↳son\n",numero_aviones_company)"""
```

Las compañías que usan cada tipo de avion son

```
avion
Airbus A320      [MoldaviAir, TabarAir, PamPangea, FlyQ, Airnar]
Airbus A380      [TabarAir, PamPangea, Airnar, MoldaviAir, FlyQ]
Boeing 737       [Airnar, FlyQ, MoldaviAir, PamPangea, TabarAir]
Boeing 747       [TabarAir, Airnar, MoldaviAir, PamPangea, FlyQ]
Name: Aircompany, dtype: object
```

'El numero de compañías que usan los distintos tipos de aviones son\n'

```
avion
Airbus A320      5
Airbus A380      5
Boeing 737       5
Boeing 747       5
Name: Aircompany, dtype: int64
```

```
[78]: ## Cual es el viaje con menor consumo por tipo de avion

viaje = df_aviones["consumo_kg"].idxmin()

for tipo_avion in df_aviones["avion"].unique():
    res = df_aviones.loc[df_aviones["avion"] == viaje]
    #print(avioneta)

#print(condicion)
print(f" EL viaje con el consumo minimo {viaje} por tipo de avion: {res}")
```

EL viaje con el consumo minimo Mol_PaLo_10737 por tipo de avion: Empty
 DataFrame
 Columns: [Aircompany, Origen, Destino, Distancia, avion, consumo_kg, duracion,
 supertrayectos]
 Index: []

[]:

```
[5]: """### Cuántos aviones usan de cada tipo en cada compañía

# creo un diccionario para guardar los resultados
dict_aviones_company = {}

# Encuentra los tipos únicos de avión
tipos = df_aviones["avion"].unique()
#print(tipos)# una lista con 4 tipos de aviones

# itero por los tipos de aviones , filtrando en el dataframe toda la
  ↳informacion
for tipo in tipos:
    avioncillos = df_aviones[df_aviones["avion"] == tipo]
    #print(avioncillos) # salen 198 elementos con informacion de todas las
    ↳columnas del DF

# Itera a través de las compañías únicas, Filtrando el DataFrame por compañía
for company in avioncillos["Aircompany"].unique():
    filas_tipo_av = avioncillos[avioncillos["Aircompany"] == company]

# Cantidad de aviones de cada tipo en cada compañía
num_aviones = len(filas_tipo_av)

# almacena el resultado en el diccionario
dict_aviones_company[(company, tipo)] = num_aviones

# Imprimo los diferentes tipos de avión que usan cada compañía, iterando por el
  ↳dict en clave y valor
for (company, tipo), numero in dict_aviones_company.items():
    print(f" La compañía {company} usa {numero} aviones , siendo sus tipos:
    ↳{tipo}")"""
```

```
[5]: '### Cuántos aviones usan de cada tipo en cada compañía\n\n# creo un diccionario
para guardar los resultados\ndict_aviones_company = {}\n\n# Encuentra los tipos
únicos de avión\ntipos = df_aviones["avion"].unique()\n#print(tipos)# una lista
con 4 tipos de aviones\n\n# itero por los tipos de aviones , filtrando en el
dataframe toda la informacion\nfor tipo in tipos:\n    avioncillos =
df_aviones[df_aviones["avion"] == tipo]\n    #print(avioncillos) # salen 198
```



```

elementos con informacion de todas las columnas del DF\n\n# Itera a través de
las compañías únicas, Filtrando el DataFrame por compañía\nfor company in
avioncillos["Aircompany"].unique():\n    filas_tipo_av =
avioncillos[avioncillos["Aircompany"] == company]\n    \n# Cantidad de aviones
de ecada tipo en cada compañía \nnum_aviones = len(filas_tipo_av)\n\n#almacena
el resultado en el diccionario\ndict_aviones_company[(company, tipo)] =
num_aviones\n\n# Imprimo los diferentes tipos de avión que usan cada compañía,
iterando por el dict en clave y calor\nfor (company, tipo), numero in
dict_aviones_company.items():\n    print(f" La compañía {company} usa {numero}
aviones , siendo sus tipos: {tipo}")'

```

```

[34]: #METODO FACIL PARA MAS ADEALNTE#
      """a_Ginebra=(df_aviones['Destino'] == "Ginebra").sum()# buscame en el DF los
      ↪vuelos con destinos, sumados previante ,a Ginebra
      print(f"Los vuelos con destino a Ginebra son un total de {a_Ginebra}")"""

```

Los vuelos con destino a Ginebra son un total de 163

```

[8]: ##### Cuántos aviones usan de cada tipo en cada compañía ##### ESTA ES LA
      ↪DEL PROFE

# itero sobre el las compañías del DF en valores unicos no todos los valores de
      ↪todas las columnas
for company in df_aviones["Aircompany"].unique():
    # da el mismo valor pero la diferencia entre poner df_aviones.Aircompany
    ↪( atributo ) y df_aviones ["Aircompany"], es que si la columna Aircompany ,
    ↪fuera Air company(separado) con el atributo daría error
    print(f" la distribucion de aviones de uso por tipo de avion para la
    ↪compañía {company} es:")
    print(df_aviones.loc[df_aviones.Aircompany == company, "avion"].
    ↪value_counts())# filtramos por sere panda en el DF por
    ↪compañías(DF[compañía]) para que nos de las columnas compañía y avion, pero
    ↪como quiero
    # saber la distrubucion de uso( realemnte el nuemro de ves que usa cada
    ↪avion cada compañía) , uso al final el metodo .value_counts()

```

la distribucion de aviones de uso por tipo de avion para la compañía Airnar es:
avion

Boeing 747	68
Airbus A380	64
Boeing 737	49
Airbus A320	37

Name: count, dtype: int64

la distribucion de aviones de uso por tipo de avion para la compañía FlyQ es:
avion

Boeing 747	67
Airbus A380	61

```

Boeing 737      54
Airbus A320     34
Name: count, dtype: int64
  la distribucion de aviones de uso por tipo de avion para la compañía TabarAir
es:
avion
Boeing 747      77
Airbus A380     71
Boeing 737      62
Airbus A320     61
Name: count, dtype: int64
  la distribucion de aviones de uso por tipo de avion para la compañía MoldaviAir
es:
avion
Boeing 737      84
Airbus A380     74
Boeing 747      71
Airbus A320     35
Name: count, dtype: int64
  la distribucion de aviones de uso por tipo de avion para la compañía PamPangea
es:
avion
Airbus A380     73
Boeing 737      66
Boeing 747      61
Airbus A320     31
Name: count, dtype: int64

```

```

[10]: # Cuántos vuelos hay a Ginebra## ESTA ES LA DEL PROFE

condicion = df_aviones ["Destino"] == "Ginebra"
print(len(df_aviones.loc[condicion])) # contamos (usamos la funcion len()) los
    ↪aviones con destino a Ginebra(condicion con una serie panda, y no tengo que
    ↪poner nada mas, porque solo quiero el numero de filas que
    #tiene destino a ginebra

# Cómo se distribuyen los origenes de los vuelos anteriores
# usaremio value_counts (distribucion)
df_aviones.loc[condicion, "Origen"].value_counts()# con uan serie panda
    ↪comprobamos la misma condicion anterior pero ahora, le pedimos tb la columna
    ↪Origen, y con el metodo vaule counts tenemos la distribucion
# del numero de vuelos

```

163

```
[10]: Origen
      Bali          32
      Nueva York    29
      Londres       21
      Cincinnati    17
      Los Angeles   17
      París         15
      Melbourne     10
      Barcelona     8
      Roma          7
      Cádiz         7
      Name: count, dtype: int64
```

Muchas de estas consultas tienen una forma alternativa y, a veces, más eficiente de realizarse. Es el caso de usar agrupaciones (groupby) y que veremos al final de la unidad

0.1.2 Manipulación de Valores

Para terminar la sesión, veamos como usar los filtros para cambiar los valores del dataframe de una forma selectiva, lo que nos vendrá muy bien en el futuro para hacer "limpieza".

```
[19]: es_TabarAir = df_aviones.Aircompany == "TabarAir" # condicion 1
a_los_Angeles = df_aviones .Destino == "Los Angeles" # condicion 2
df_aviones.loc[es_TabarAir & a_los_Angeles, "Destino"] = "San Francisco" # con_
    ↪uan sere panda comprubo las filas del DF las que cumplen las 2 condciones y_
    ↪despues de la coma,
#ponermos la columna destino ques es lo que quiero cambiar
# como comprobamos si lo ha cambiado pues preguntado la condicion, si dice que_
    ↪no hay vuelos se ha cambiado:
df_aviones.loc[es_TabarAir & a_los_Angeles]
# ahora miramos en las 20 filas si se ha cambiado ya que no muestra ninguno al_
    ↪imprimir la condicion
df_aviones.head(20)
# lo que no hemos cambiado su identificador, podriamos dicho cambiamos en la_
    ↪misma condicionm cambiar el indice y despues el destino (lo veremos mas_
    ↪adelante)
```

```
[19]:
```

	Aircompany	Origen	Destino	Distancia	\
Id_vuelo					
Air_PaGi_10737	Airnar	París	Ginebra	411	
Fly_BaRo_10737	FlyQ	Bali	Roma	12738	
Tab_GiLo_11380	TabarAir	Ginebra	San Francisco	9103	
Mol_PaCi_10737	MoldaviAir	París	Cincinnati	6370	
Tab_CiRo_10747	TabarAir	Cincinnati	Roma	7480	
Mol_CaMe_10737	MoldaviAir	Cádiz	Melbourne	20029	
Mol_PaLo_11320	MoldaviAir	París	Londres	344	
Pam_PaMe_11380	PamPangea	París	Melbourne	16925	
Pam_NuBa_10737	PamPangea	Nueva York	Bali	16589	

Air_GiCa_11380	Airnar	Ginebra	Cádiz	1725
Tab_LoCi_10737	TabarAir	Los Angeles	Cincinnati	3073
Mol_LoBa_11380	MoldaviAir	Londres	Bali	12553
Tab_CiLo_10747	TabarAir	Cincinnati	San Francisco	3073
Tab_GiLo_11380	TabarAir	Ginebra	Londres	739
Tab_CiRo_11320	TabarAir	Cincinnati	Roma	7480
Tab_RoLo_10747	TabarAir	Roma	San Francisco	10077
Mol_MeCa_10737	MoldaviAir	Melbourne	Cádiz	20029
Air_GiLo_10747	Airnar	Ginebra	Los Angeles	9103
Pam_MePa_10737	PamPangea	Melbourne	París	16925
Pam_GiNu_11320	PamPangea	Ginebra	Nueva York	6206

	avion	consumo_kg	duracion
Id_vuelo			
Air_PaGi_10737	Boeing 737	1028.691900	51
Fly_BaRo_10737	Boeing 737	33479.132544	1167
Tab_GiLo_11380	Airbus A380	109439.907200	626
Mol_PaCi_10737	Boeing 737	17027.010000	503
Tab_CiRo_10747	Boeing 747	86115.744000	518
Mol_CaMe_10737	Boeing 737	53148.153240	1721
Mol_PaLo_11320	Airbus A320	915.246400	44
Pam_PaMe_11380	Airbus A380	217722.658400	1328
Pam_NuBa_10737	Boeing 737	45277.618464	1459
Air_GiCa_11380	Airbus A380	20339.820000	135
Tab_LoCi_10737	Boeing 737	7915.433400	253
Mol_LoBa_11380	Airbus A380	156721.694400	856
Tab_CiLo_10747	Boeing 747	32758.180000	224
Tab_GiLo_11380	Airbus A380	8542.840000	69
Tab_CiRo_11320	Airbus A320	21087.855360	662
Tab_RoLo_10747	Boeing 747	109569.236400	691
Mol_MeCa_10737	Boeing 737	51629.634576	1721
Air_GiLo_10747	Boeing 747	104801.018400	626
Pam_MePa_10737	Boeing 737	46622.417400	1485
Pam_GiNu_11320	Airbus A320	16200.142400	569

Supongamos que nos avisan de que los datos de TabarAir son erróneos porque para los vuelos a Los Angeles en realidad son a San Francisco. ¿Cómo podríamos cambiar ese valor?

[]:

Y ahora nos dicen que creamos una columna nueva "Supertrayectos" que debe ser True cuando el trayecto es mayor de 12000Km y False en caso contrario

[20]: *# Creandolo con un filtro/Selección*
cuanno nos pidan cambiar una columna y despues cambair los valores, nos
↪ crearemos la columna con un valor por defecto , y asi no te de problemas de
↪ referencia e igrularlos a False

```
df_aviones["supertrayectos"] = False # condicion que decimos que todos los
↳ valores valen False y despues:
df_aviones.loc[df_aviones.Distancia > 12000, "supertrayectos"] = True # despues
↳ con una serie panda extraemos del DF las filas con distancia >120000, y
↳ despues la columna que quiero cambiar y el valor lo cambiamos a true
# asi todos los valores seran false menos los que sea mayores a 12000
df_aviones
```

```
[20]:
```

	Aircompany	Origen	Destino	Distancia	\
Id_vuelo					
Air_PaGi_10737	Airnar	París	Ginebra	411	
Fly_BaRo_10737	FlyQ	Bali	Roma	12738	
Tab_GiLo_11380	TabarAir	Ginebra	San Francisco	9103	
Mol_PaCi_10737	MoldaviAir	París	Cincinnati	6370	
Tab_CiRo_10747	TabarAir	Cincinnati	Roma	7480	
...	
Tab_LoLo_11320	TabarAir	Los Angeles	Londres	8785	
Mol_CiLo_10737	MoldaviAir	Cincinnati	Londres	6284	
Fly_RoCi_11320	FlyQ	Roma	Cincinnati	7480	
Tab_RoLo_10747	TabarAir	Roma	Londres	1433	
Air_PaLo_10737	Airnar	París	Los Angeles	9099	

	avion	consumo_kg	duracion	supertrayectos
Id_vuelo				
Air_PaGi_10737	Boeing 737	1028.691900	51	False
Fly_BaRo_10737	Boeing 737	33479.132544	1167	True
Tab_GiLo_11380	Airbus A380	109439.907200	626	False
Mol_PaCi_10737	Boeing 737	17027.010000	503	False
Tab_CiRo_10747	Boeing 747	86115.744000	518	False
...
Tab_LoLo_11320	Airbus A320	24766.953120	756	False
Mol_CiLo_10737	Boeing 737	16491.729600	497	False
Fly_RoCi_11320	Airbus A320	19721.049920	662	False
Tab_RoLo_10747	Boeing 747	15734.053400	115	False
Air_PaLo_10737	Boeing 737	22331.675700	711	False

[1200 rows x 8 columns]

```
[25]: # pero despue spodemos hacer
df_aviones.loc[df_aviones.supertrayectos, "Destino"].value_counts()#
↳ comprobamos en el DF con serie panda, la fila nueva creada, y recupero
↳ "Destino" , pq quier saber la distrbucion de destinos
# me da el numero de destinos que han recorrido mas de 12000 km
```

```
[25]: Destino
Bali      114
Melbourne 68
```

```

Londres      47
Ginebra      42
Cincinnati  36
Cádiz        22
París        19
Nueva York   18
Roma         16
Barcelona     7
Los Angeles   3
Name: count, dtype: int64

```

```

[26]: # Versión alternativa(la de arriba mejor)

df_aviones["supertrayectos"] = df_aviones["Distancia"] >12000 # directamente
↳ creo la columna de supertrayectos a partir de la condicion (> 120000km)
df_aviones

```

```

[26]:
      Aircompany      Origen      Destino  Distancia \
Id_vuelo
Air_PaGi_10737    Airnar      París      Ginebra      411
Fly_BaRo_10737    FlyQ        Bali        Roma      12738
Tab_GiLo_11380    TabarAir     Ginebra    San Francisco      9103
Mol_PaCi_10737    MoldaviAir    París      Cincinnati      6370
Tab_CiRo_10747    TabarAir     Cincinnati      Roma      7480
...
Tab_LoLo_11320    TabarAir    Los Angeles      Londres      8785
Mol_CiLo_10737    MoldaviAir     Cincinnati      Londres      6284
Fly_RoCi_11320    FlyQ        Roma      Cincinnati      7480
Tab_RoLo_10747    TabarAir      Roma      Londres      1433
Air_PaLo_10737    Airnar      París      Los Angeles      9099

      avion      consumo_kg  duracion  supertrayectos
Id_vuelo
Air_PaGi_10737  Boeing 737    1028.691900      51      False
Fly_BaRo_10737  Boeing 737    33479.132544    1167      True
Tab_GiLo_11380  Airbus A380  109439.907200      626      False
Mol_PaCi_10737  Boeing 737    17027.010000      503      False
Tab_CiRo_10747  Boeing 747    86115.744000      518      False
...
Tab_LoLo_11320  Airbus A320   24766.953120      756      False
Mol_CiLo_10737  Boeing 737    16491.729600      497      False
Fly_RoCi_11320  Airbus A320   19721.049920      662      False
Tab_RoLo_10747  Boeing 747    15734.053400      115      False
Air_PaLo_10737  Boeing 737    22331.675700      711      False

```

```
[1200 rows x 8 columns]
```

En sesiones posteriores veremos la forma de manipular valores utilizando funciones definidas por el

usuario, con lo que terminarás de ver ya casi todo el potencial de manipulación de datos a partir de un `DataFrame`.